

大模型压缩训练

知识蒸馏




课程内容

1. 模型压缩方法介绍
 2. 模型剪枝、量化与知识蒸馏
 3. 知识蒸馏在大模型中的应用
 4. 如何使用知识蒸馏法快速训练大模型
- 案例：基于Qwen模型的知识蒸馏案例

模型压缩简介

- 深度学习（Deep Learning）因其计算复杂度或参数冗余，在一些场景和设备上限制了相应的模型部署，需要借助模型压缩、优化加速、异构计算等方法突破瓶颈。
- 模型压缩算法能够有效降低参数冗余，从而减少存储占用、通信带宽和计算复杂度，有助于深度学习的应用部署，具体可划分为如下几种方法（后续重点介绍剪枝与量化）：
 - ① 线性或非线性量化：1/2bits, int8 和 fp16等；
 - ② 结构或非结构剪枝：deep compression, channel pruning 和 network slimming等；
 - ③ 知识蒸馏与网络结构简化（squeeze-net, mobile-net, shuffle-net）等；


剪枝简介



剪枝方式

- 非结构剪枝：通常是连接级、细粒度的剪枝方法，精度相对较高，但依赖于特定算法库或硬件平台的支持
- 结构剪枝：是filter级或layer级、粗粒度的剪枝方法，精度相对较低，但剪枝策略更为有效，不需要特定算法库或硬件平台的支持，能够直接在成熟深度学习框架上运行
- 局部方式的、通过layer by layer方式的、最小化输出FM重建误差的Channel Pruning, ThiNet Discrimination-aware Channel Pruning ;
- 全局方式的、通过训练期间对BN层Gamma系数施加L1正则约束的Network Slimming

剪枝方式



Fine-grained
Pruning




Vector-level
Pruning



Kernel-level
Pruning



Group-level
Pruning



Filter-level
Pruning

剪枝效果

Table 1: Model size and accuracy tradeoff for sparse-InceptionV3

Sparsity	NNZ params	Top-1 acc.	Top-5 acc.
0%	27.1M	78.1%	94.3%
50%	13.6M	78.0%	94.2%
75%	6.8M	76.1%	93.2%
87.5%	3.3M	74.6%	92.5%

Table 2: MobileNets sparse vs dense results

Width	Sparsity	NNZ params	Top-1 acc.	Top-5 acc.
0.25	0%	0.46M	50.6%	75.0%
0.5	0%	1.32M	63.7%	85.4%
0.75	0%	2.57M	68.4%	88.2%
1.0	0%	4.21M	70.6%	89.5%
	50%	2.13M	69.5%	89.5%
	75%	1.09M	67.7%	88.5%
	90%	0.46M	61.8%	84.7%
	95%	0.25M	53.6%	78.9%

量化（学术界）

- 低精度（Low precision）可能是最通用的概念。常规精度一般使用 FP32（32位浮点，单精度）存储模型权重；低精度则表示 FP16（半精度浮点），INT8（8位的定点整数）等等数值格式。不过目前低精度往往指代 INT8。
- 混合精度（Mixed precision）在模型中使用 FP32 和 FP16 。 FP16 减少了一半的内存大小，但有些参数或操作符必须采用 FP32 格式才能保持准确度。如果您对该主题感兴趣，请查看 [Mixed-Precision Training of Deep Neural Networks](#) 。
- 量化一般指 INT8 。
- 根据存储一个权重元素所需的位数，还可以包括：
 - ① 二值神经网络：在运行时权重和激活只取两种值（例如 +1, -1）的神经网络，以及在训练时计算参数的梯度。
 - ② 三元权重网络：权重约束为+1, 0和-1的神经网络。
 - ③ XNOR网络：过滤器和卷积层的输入是二进制的。 XNOR 网络主要使用二进制运算来近似卷积。


量化（工业界）

理论是一回事，实践是另一回事。如果一种技术方法难以推广到通用场景，则需要进行大量的额外支持。花哨的研究往往是过于棘手或前提假设过强，以至几乎无法引入工业界的软件栈。

工业界最终选择了 INT8 量化—— FP32 在推理（inference）期间被 INT8 取代，而训练（training）仍然是 FP32。TensorRT, TensorFlow, PyTorch, MxNet 和许多其他深度学习软件都已启用（或正在启用）量化。

通常，可以根据 FP32 和 INT8 的转换机制对解决方案进行分类。一些框架简单地引入了 Quantize 和 Dequantize 层，当从卷积或全链接层送入或取出时，它将 FP32 转换为 INT8 或相反。在这种情况下，如图四的上半部分所示，模型本身和输入/输出采用 FP32 格式。深度学习框架加载模型，重写网络以插入 Quantize 和 Dequantize 层，并将权重转换为 INT8 格式。

量化原理



知识蒸馏




Figure 1: The network architecture of our DarkRank method. The student network is trained with standard classification loss, contrastive loss and triplet loss as well as the similarity transfer loss proposed by us.

$$q_i = \frac{\exp(z_i / T)}{\sum_j \exp(z_j / T)}$$

知识蒸馏在大模型中的应用

DeepSeek作为中国人工智能领域的代表性大模型，其训练过程中深度应用了知识蒸馏技术（Knowledge Distillation），通过将大模型的知识迁移至小模型，实现了性能与效率的平衡。

知识蒸馏在DeepSeek中的核心意义

1. 降低算力与成本

DeepSeek通过蒸馏技术将模型训练成本压缩至OpenAI同类模型的1/20。例如，DeepSeek-V3仅消耗278.8万GPU小时（成本约557.6万美元），而OpenAI类似模型的训练成本高达数亿美元49。这种低成本特性使中小企业也能负担高性能AI模型的开发。

2. 加速推理与边缘部署

蒸馏后的小模型（如32B/70B版本）推理速度提升3倍以上，延迟从850ms降至150ms，显存占用从320GB减少至8GB。这使得模型可在手机、工业设备等边缘端实时运行，满足医疗诊断、自动驾驶等场景的低延迟需求

知识蒸馏在DeepSeek中的核心意义

3. 推动行业应用落地

教育领域：DeepSeek蒸馏模型可快速生成个性化学习内容，根据学生反馈动态调整教学策略，降低教育平台运营成本。

工业场景：本地化部署的蒸馏模型减少对云端的依赖，数据隐私与响应速度显著提升，助力智能制造中的质检、供应链优化等任务。

内容创作：AI写作工具结合蒸馏模型，创作效率提升50%，同时API调用成本仅为OpenAI的1/4，推动新媒体运营与创意产业发展。

知识蒸馏在DeepSeek中的核心意义

4. 技术自主可控

面对美国GPU芯片禁运，DeepSeek通过蒸馏技术降低对算力的依赖，结合FP8混合精度训练和DualPipe流水线机制，在国产芯片（如华为昇腾）上实现高性能推理，增强中国AI产业的自主可控能力。

课后作业

1. 掌握AI模型压缩技术的基本概念
2. 掌握知识蒸馏在大模型中的应用价值。



End



Thanks