

xtuner微调大模型教程

xtuner微调大模型教程

- 1.构建虚拟环境
- 2.下载模型
- 3.微调
- 4.微调训练
- 5.模型转换
- 6.模型合并

1.构建虚拟环境

```
conda create --name xtuner-env python=3.10 -y
conda activate xtuner-env
```

拉取 XTuner，过程大约需要几分钟

```
git clone https://github.com/InternLM/xtuner.git
```

然后安装依赖的软件，这步需要的时间比较长。

```
cd xtuner
pip install -e '[all]'
```

等以上所有步骤完成后，再进行下面的操作。

2.下载模型

```
from modelscope import snapshot_download
model_dir = snapshot_download('Shanghai_AI_Laboratory/internlm2-chat-1.8b',cache_dir='/root/llm/internlm2-1.8b-chat')
```

3.微调

创建微调训练相关的配置文件在左侧的文件列表，xtuner 的文件夹里，打开 xtuner/xtuner/configs/internlm/internlm2_chat_1.8b/internlm2_chat_1.8b_qlora_alpaca_e3.py，复制一份至根目录。
打开这个文件，然后修改预训练模型地址，数据文件地址等。

```
### PART 1中

#预训练模型存放的位置
pretrained_model_name_or_path = '/root/llm/internlm2-1.8b-chat'
#微调数据存放的位置

data_files = '/root/public/data/target_data.json'#底座模型路径
```

```
# 训练中最大的文本长度

max_length = 512

# 每一批训练样本的大小

batch_size = 2
#最大训练轮数
max_epochs = 3

#验证数据
evaluation_inputs = [
    '只剩一个心脏了还能活吗？', '爸爸再婚，我是不是就有了个新娘？',
    '樟脑丸是我吃过最难吃的硬糖有奇怪的味道怎么还有人买', '马上要上游泳课了，昨天洗的泳裤还没干，怎么办',
    '我只出生了一次，为什么每年都要庆生'
]

# PART 3中

dataset=dict(type=load_dataset, path="json", data_files=data_files)
dataset_map_fn=None
```

4.微调训练

在当前目录下，输入以下命令启动微调脚本

```
xtuner train internlm2_chat_1_8b_qlora_alpaca_e3.py
```

5.模型转换

模型训练后会自动保存成 PTH 模型（例如 `iter_2000.pth`，如果使用了 DeepSpeed，则将会是一个文件夹），我们需要利用 `xtuner convert pth_to_hf` 将其转换为 HuggingFace 模型，以便于后续使用。具体命令为：

```
xtuner convert pth_to_hf ${FINETUNE_CFG} ${PTH_PATH} ${SAVE_PATH}
# 例如: xtuner convert pth_to_hf internlm2_chat_7b_qlora_custom_sft_e1_copy.py
./iter_2000.pth ./iter_2000_
```

6.模型合并

如果使用了 LoRA / QLoRA 微调，则模型转换后将得到 adapter 参数，而并不包含原 LLM 参数。如果您期望获得合并后的模型权重（例如用于后续评测），那么可以利用 `xtuner convert merge`：

```
$ xtuner convert merge ${LLM} ${LLM_ADAPTER} ${SAVE_PATH}
```

附：xtuner中文文档<https://xtuner.readthedocs.io/zh-cn/latest/index.html>

